



矩阵微积分

耿修瑞


中国科学院空间信息创新研究院

gengxr@sina.com.cn

2025.3

- 几个常用例子
- 实值（向量）函数相对于实向量的梯度
- 实值函数相对于矩阵的梯度
- 矩阵微分
- 迹函数的矩阵梯度
- 行列式的矩阵梯度
- Hessian矩阵和投影Hessian矩阵

□ 函数 $f(x, y) = 5(x + y)$ 的梯度（线性）




$$f(x, y) = 5(x + y) = 5\mathbf{x}^T \mathbf{1}$$

$$\mathbf{x} = [x \ y]^T, \mathbf{1} = [1 \ 1]^T$$

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = [5 \ 5]^T$$

□ 函数 $f(x, y) = \frac{1}{2}(x^2 + y^2)$ 的梯度 (二次型)



$$f(x, y) = \frac{1}{2}(x^2 + y^2) = \frac{1}{2} \mathbf{x}^T \mathbf{x}$$


$$\mathbf{x} = \begin{bmatrix} x & y \end{bmatrix}^T$$

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{x}$$

常用例子-3



□ 函数 $f(x, y) = \frac{x^2}{a^2} + \frac{y^2}{b^2}$ 的梯度（二次型）



$$f(x, y) = \frac{x^2}{a^2} + \frac{y^2}{b^2}$$


$$= \begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} 1/a^2 & 0 \\ 0 & 1/b^2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

$$= \mathbf{x}^T \begin{bmatrix} 1/a^2 & 0 \\ 0 & 1/b^2 \end{bmatrix} \mathbf{x}$$

$$\mathbf{x} = \begin{bmatrix} x & y \end{bmatrix}^T$$


$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2 \begin{bmatrix} 1/a^2 & 0 \\ 0 & 1/b^2 \end{bmatrix} \mathbf{x} = \begin{bmatrix} \frac{2x}{a^2} \\ \frac{2y}{b^2} \end{bmatrix}$$

□ 迹函数相对于矩阵的梯度



$$\frac{\partial \text{tr}(\mathbf{Z}\mathbf{Z}^T)}{\partial \mathbf{Z}} = \frac{\partial \text{tr}(\mathbf{Z}^T\mathbf{Z})}{\partial \mathbf{Z}} = 2\mathbf{Z}$$

□ 行列式相对于矩阵的梯度 $\frac{\partial |\mathbf{Z}|}{\partial \mathbf{Z}} = |\mathbf{Z}| \mathbf{Z}^{-T}$



$$\mathbf{Z} = \begin{bmatrix} 1 & 1 & 1 \\ x_A & x_B & x_C \\ y_A & y_B & y_C \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 3 & 7 & 3 \\ 3 & 3 & 6 \end{bmatrix}$$


$$S_{ABC} = \frac{1}{2} |\mathbf{Z}| = \frac{1}{2} \det \begin{bmatrix} 1 & 1 & 1 \\ 3 & 7 & 3 \\ 3 & 3 & 6 \end{bmatrix}$$

$$\frac{\partial |\mathbf{Z}|}{\partial \mathbf{Z}} = \begin{bmatrix} 1 & 1 & 1 \\ 3 & 7 & 3 \\ 3 & 3 & 6 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 3 & 7 & 3 \\ 3 & 3 & 6 \end{bmatrix}^{-T} = \begin{bmatrix} 33 & -9 & -12 \\ -3 & 3 & 0 \\ -4 & 0 & 4 \end{bmatrix}$$

常用例子-5

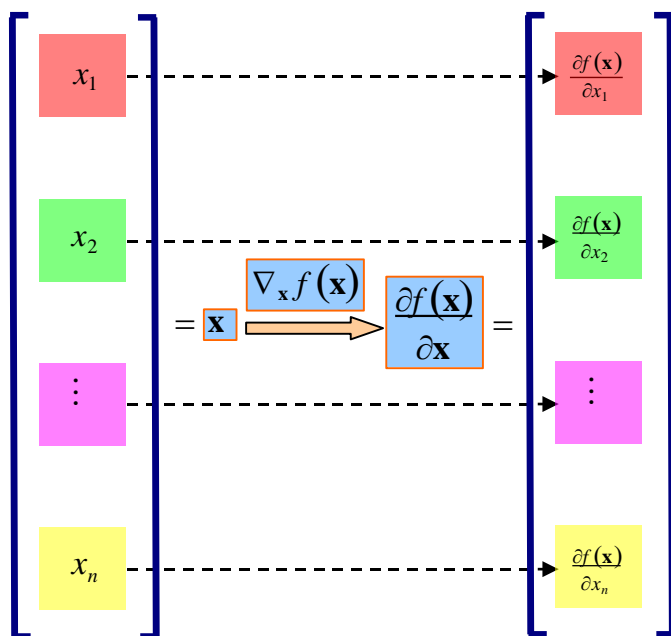


□ 行列式相对于矩阵的梯度 $\frac{\partial |\mathbf{Z}|}{\partial \mathbf{Z}} = |\mathbf{Z}| \mathbf{Z}^{-T}$



□ 实值标量函数对于实向量的梯度

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1} \quad \frac{\partial f(\mathbf{x})}{\partial x_2} \quad \dots \quad \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}}$$



1. 以列（行）向量为自变量的标量函数，其对于自变量的梯度仍然为一阶数相同的列（行）向量
2. 梯度的每个分量代表着函数在该分量方向上的变化率。

□ 实值向量函数对于实向量的梯度

$$\mathbf{f}(\mathbf{x}) = [f_1(\mathbf{x}) \quad f_2(\mathbf{x}) \quad \cdots \quad f_m(\mathbf{x})]^T$$

$$\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial \mathbf{x}^T} \\ \frac{\partial f_2(\mathbf{x})}{\partial \mathbf{x}^T} \\ \vdots \\ \frac{\partial f_m(\mathbf{x})}{\partial \mathbf{x}^T} \end{bmatrix} = \begin{bmatrix} \frac{\partial \mathbf{f}(\mathbf{x})}{\partial x_1} & \frac{\partial \mathbf{f}(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial \mathbf{f}(\mathbf{x})}{\partial x_n} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \frac{\partial f_1(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial f_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial f_2(\mathbf{x})}{\partial x_1} & \frac{\partial f_2(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial f_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m(\mathbf{x})}{\partial x_1} & \frac{\partial f_m(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix} = \left(\frac{\partial \mathbf{f}^T(\mathbf{x})}{\partial \mathbf{x}} \right)^T$$

1. 向量函数对于向量的求导，相当于向量函数中的每一个分量函数对向量求导或者向量函数对向量的每一个分量求导。
2. 行向量函数对列向量自变量求导形成矩阵；列向量函数对行向量自变量求导也可以形成矩阵。

实值函数相对于实向量的梯度



□ 例1 $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} = \mathbf{x}^T \mathbf{a} = a_1 x_1 + a_2 x_2 + \cdots + a_n x_n$

$$\begin{aligned} \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} &= \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \left[\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial x_1} \quad \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial x_2} \quad \cdots \quad \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial x_n} \right]^T \\ &= [a_1 \quad a_2 \quad \cdots \quad a_n]^T = \mathbf{a} \end{aligned}$$

$$\begin{aligned} \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} &= \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}^T} = \left[\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial x_1} \quad \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial x_2} \quad \cdots \quad \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial x_n} \right] \\ &= [a_1 \quad a_2 \quad \cdots \quad a_n] = \mathbf{a}^T \end{aligned}$$

实值函数相对于实向量的梯度



□ 例2 $\mathbf{f}(\mathbf{x}) = \mathbf{x} = [x_1 \quad x_2 \quad \cdots \quad x_n]^T$

$$\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}^T} = \frac{\partial \mathbf{x}}{\partial \mathbf{x}^T} = \mathbf{I}_{n \times n}$$

$$\frac{\partial (\mathbf{f}(\mathbf{x}))^T}{\partial \mathbf{x}} = \frac{\partial \mathbf{x}^T}{\partial \mathbf{x}} = \mathbf{I}_{n \times n} = \left(\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}^T} \right)^T$$

$$\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}} = \frac{\partial \mathbf{x}}{\partial \mathbf{x}} = \text{vec}(\mathbf{I}_{n \times n})$$

$$\frac{\partial (\mathbf{f}(\mathbf{x}))^T}{\partial \mathbf{x}^T} = \frac{\partial \mathbf{x}^T}{\partial \mathbf{x}^T} = (\text{vec}(\mathbf{I}_{n \times n}))^T = \left(\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}} \right)^T$$

实值函数相对于实向量的梯度



□ 例3 $\mathbf{f}(\mathbf{x}) = \mathbf{A}\mathbf{x}$

$$\mathbf{f}(\mathbf{x}) = \mathbf{A}\mathbf{x} = \begin{bmatrix} \mathbf{A}(1,:) \mathbf{x} \\ \mathbf{A}(2,:) \mathbf{x} \\ \vdots \\ \mathbf{A}(m,:) \mathbf{x} \end{bmatrix}$$

$$\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial \mathbf{A}(1,:) \mathbf{x}}{\partial \mathbf{x}^T} \\ \frac{\partial \mathbf{A}(2,:) \mathbf{x}}{\partial \mathbf{x}^T} \\ \vdots \\ \frac{\partial \mathbf{A}(m,:) \mathbf{x}}{\partial \mathbf{x}^T} \end{bmatrix} = \begin{bmatrix} \mathbf{A}(1,:) \\ \mathbf{A}(2,:) \\ \vdots \\ \mathbf{A}(m,:) \end{bmatrix} = \mathbf{A}$$

实值函数相对于实向量的梯度



□ 例3 $\mathbf{f}(\mathbf{x}) = \mathbf{A}\mathbf{x}$

方法2:

$$\mathbf{f}(\mathbf{x}) = \mathbf{A}\mathbf{x} = x_1\mathbf{A}(:,1) + x_2\mathbf{A}(:,2) + \cdots + x_n\mathbf{A}(:,n)$$

$$\begin{aligned}\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}^T} &= \left[\frac{\partial \mathbf{f}(\mathbf{x})}{\partial x_1} \quad \frac{\partial \mathbf{f}(\mathbf{x})}{\partial x_2} \quad \cdots \quad \frac{\partial \mathbf{f}(\mathbf{x})}{\partial x_n} \right] \\ &= \left[\mathbf{A}(:,1) \quad \mathbf{A}(:,2) \quad \cdots \quad \mathbf{A}(:,n) \right] \\ &= \mathbf{A}\end{aligned}$$

实值函数相对于实向量的梯度



□ 例4 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$

方法1：逐元素求导

$$f(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$$

与 x_k 相关的项 $\sum_{j=1, j \neq k}^n a_{kj} x_k x_j + \sum_{i=1, i \neq k}^n a_{ik} x_i x_k + a_{kk} x_k^2$

$$\frac{\partial f(\mathbf{x})}{\partial x_k} = \sum_{j=1, j \neq k}^n a_{kj} x_j + \sum_{i=1, i \neq k}^n a_{ik} x_i + 2a_{kk} x_k = \sum_{j=1}^n a_{kj} x_j + \sum_{i=1}^n a_{ik} x_i$$

$$= \mathbf{A}(k, :) \mathbf{x} + \mathbf{A}(:, k)^T \mathbf{x} = \left(\mathbf{A}(k, :) + \mathbf{A}(:, k)^T \right) \mathbf{x}$$

$$\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}} = \mathbf{A} \mathbf{x} + \mathbf{A}^T \mathbf{x} \quad \text{当} \mathbf{A} \text{为对称矩阵时} = 2\mathbf{A} \mathbf{x}$$

□ 常用梯度公式及求导法则

● 线性法则

$$\frac{\partial (c_1 f(\mathbf{x}) + c_2 g(\mathbf{x}))}{\partial \mathbf{x}} = c_1 \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} + c_2 \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$$

● 乘积法则

$$\frac{\partial (f(\mathbf{x}) g(\mathbf{x}))}{\partial \mathbf{x}} = g(\mathbf{x}) \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} + f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$$

● 商法则

$$\frac{\partial (f(\mathbf{x}) / g(\mathbf{x}))}{\partial \mathbf{x}} = \frac{1}{g^2(\mathbf{x})} \left(g(\mathbf{x}) \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} - f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} \right)$$

● 链式法则

$$\frac{\partial (f(\mathbf{g}(\mathbf{x})))}{\partial \mathbf{x}} = \frac{\partial \mathbf{g}^T(\mathbf{x})}{\partial \mathbf{x}} \frac{\partial f(\mathbf{g})}{\partial \mathbf{g}}$$

□ 常用梯度公式及求导法则

- 函数 $f(\mathbf{x}) = \mathbf{g}(\mathbf{x})^T \mathbf{h}(\mathbf{x})$

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \frac{\partial \mathbf{g}(\mathbf{x})^T}{\partial \mathbf{x}} \mathbf{h}(\mathbf{x}) + \frac{\partial \mathbf{h}(\mathbf{x})^T}{\partial \mathbf{x}} \mathbf{g}(\mathbf{x})$$

- 函数 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|^2$

$$\frac{\partial \mathbf{x}^T \mathbf{x}}{\partial \mathbf{x}} = 2\mathbf{x}$$

□ 实值函数 $f(\mathbf{A})$ 相对于其自变量 $m \times n$ 矩阵 \mathbf{A} 的梯度定义为

$$\frac{\partial f(\mathbf{A})}{\partial \mathbf{A}} = \begin{bmatrix} \frac{\partial f(\mathbf{A})}{\partial a_{11}} & \frac{\partial f(\mathbf{A})}{\partial a_{12}} & \dots & \frac{\partial f(\mathbf{A})}{\partial a_{1n}} \\ \frac{\partial f(\mathbf{A})}{\partial a_{21}} & \frac{\partial f(\mathbf{A})}{\partial a_{22}} & \dots & \frac{\partial f(\mathbf{A})}{\partial a_{2n}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f(\mathbf{A})}{\partial a_{m1}} & \frac{\partial f(\mathbf{A})}{\partial a_{m2}} & \dots & \frac{\partial f(\mathbf{A})}{\partial a_{mn}} \end{bmatrix} = \nabla_{\mathbf{A}} f(\mathbf{A})$$

1. 实值函数相对于矩阵的梯度仍然为一与矩阵同阶的矩阵
2. 实值函数相对于矩阵的梯度矩阵的每一个分量对应于该函数在矩阵的每一个分量的变化率。

- 实值函数相对于矩阵的求导和相对于向量的求导本质上没有区别

$$\frac{\partial f(\text{vec}(\mathbf{A}))}{\partial \text{vec}(\mathbf{A})} = \begin{bmatrix} \frac{\partial f(\mathbf{A})}{\partial a_{11}} \\ \vdots \\ \frac{\partial f(\mathbf{A})}{\partial a_{m1}} \\ \vdots \\ \frac{\partial f(\mathbf{A})}{\partial a_{1n}} \\ \vdots \\ \frac{\partial f(\mathbf{A})}{\partial a_{mn}} \end{bmatrix} = \nabla_{\text{vec}(\mathbf{A})} f(\text{vec}(\mathbf{A}))$$

$$\nabla_{\mathbf{A}} f(\mathbf{A}) = \text{unvec}(\nabla_{\text{vec}(\mathbf{A})} f(\text{vec}(\mathbf{A})))$$

□ 例：求 $f(\mathbf{A}) = \mathbf{x}^T \mathbf{A} \mathbf{y}$ 相对于矩阵 \mathbf{A} 的梯度。

方法1：逐元素求导

$$f(\mathbf{A}) = \mathbf{x}^T \mathbf{A} \mathbf{y} = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_i y_j$$

$$\frac{\partial f(\mathbf{A})}{\partial a_{ij}} = x_i y_j$$

$$\frac{\partial f(\mathbf{A})}{\partial \mathbf{A}} = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_n \\ \vdots & \vdots & \ddots & \vdots \\ x_m y_1 & x_m y_2 & \cdots & x_m y_n \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_m \end{bmatrix} \begin{bmatrix} y_1 & \cdots & y_n \end{bmatrix} = \mathbf{x} \mathbf{y}^T$$

实值函数相对于矩阵的梯度



□ 例：求 $f(\mathbf{A}) = \mathbf{x}^T \mathbf{A} \mathbf{y}$ 相对于矩阵 \mathbf{A} 的梯度。

方法2：向量求导法

$$f(\mathbf{A}) = \mathbf{x}^T \mathbf{A} \mathbf{y} = \text{vec}(\mathbf{A})^T \text{kron}(\mathbf{y}, \mathbf{x}) = \text{kron}(\mathbf{y}^T, \mathbf{x}^T) \text{vec}(\mathbf{A})$$

$$\frac{\partial f(\text{vec}(\mathbf{A}))}{\partial \text{vec}(\mathbf{A})} = \text{kron}(\mathbf{y}, \mathbf{x})$$

$$\text{vec}(\mathbf{ABC}) = (\mathbf{C}^T \otimes \mathbf{A}) \text{vec}(\mathbf{B})$$

$$\nabla_{\mathbf{A}} f(\mathbf{A}) = \text{unvec}\left(\nabla_{\text{vec}(\mathbf{A})} f(\text{vec}(\mathbf{A}))\right) = \text{unvec}(\text{kron}(\mathbf{y}, \mathbf{x})) = \mathbf{x} \mathbf{y}^T$$

$$\text{kron}(\mathbf{X}, \mathbf{Y}) = \mathbf{X} \otimes \mathbf{Y} = \begin{bmatrix} x_{11} \mathbf{Y} & \cdots & x_{1n} \mathbf{Y} \\ \vdots & \ddots & \vdots \\ x_{m1} \mathbf{Y} & \cdots & x_{mn} \mathbf{Y} \end{bmatrix}$$

□ 常用梯度公式及求导法则

● 线性法则

$$\frac{\partial(c_1 f(\mathbf{A}) + c_2 g(\mathbf{A}))}{\partial \mathbf{A}} = c_1 \frac{\partial f(\mathbf{A})}{\partial \mathbf{A}} + c_2 \frac{\partial g(\mathbf{A})}{\partial \mathbf{A}}$$

● 乘积法则

$$\frac{\partial f(\mathbf{A}) g(\mathbf{A})}{\partial \mathbf{A}} = g(\mathbf{A}) \frac{\partial f(\mathbf{A})}{\partial \mathbf{A}} + f(\mathbf{A}) \frac{\partial g(\mathbf{A})}{\partial \mathbf{A}}$$

● 商法则

$$\frac{\partial(f(\mathbf{A})/g(\mathbf{A}))}{\partial \mathbf{A}} = \frac{1}{g^2(\mathbf{A})} \left(g(\mathbf{A}) \frac{\partial f(\mathbf{A})}{\partial \mathbf{A}} - f(\mathbf{A}) \frac{\partial g(\mathbf{A})}{\partial \mathbf{A}} \right)$$

● 链式法则

$$\frac{\partial g(f(\mathbf{A}))}{\partial \mathbf{A}} = \frac{dg(y)}{dy} \frac{\partial f(\mathbf{A})}{\partial \mathbf{A}}$$

- 对于一个以向量 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ 为变量的实值函数 $f(\mathbf{x})$ ，其微分公式定义如下

$$df(\mathbf{x}) = \sum_{i=1}^n \frac{\partial f(\mathbf{x})}{\partial x_i} dx_i$$

- 对于一个以 $m \times n$ 阶矩阵 \mathbf{X} 为变量的实值函数 $f(\mathbf{x})$ ，其微分公式定义如下

$$df(\mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial f(\mathbf{X})}{\partial x_{ij}} dx_{ij}$$

□ 重要公式

$$d\mathbf{X} = \begin{bmatrix} dx_{11} & dx_{12} & \cdots & dx_{1n} \\ dx_{21} & dx_{22} & \cdots & dx_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ dx_{m1} & dx_{m2} & \cdots & dx_{mn} \end{bmatrix} = \sum_{i=1}^m \sum_{j=1}^n \mathbf{e}_i \hat{\mathbf{e}}_j^T dx_{ij}$$

$$\frac{\partial \mathbf{X}}{\partial x_{ij}} = \mathbf{e}_i \hat{\mathbf{e}}_j^T$$

□ 非常重要的一个公式

$$df(\mathbf{X}) = \text{tr} \left(\left(\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} \right)^T d\mathbf{X} \right)$$

□ 矩阵微分满足如下规则

➤ 线性法则

$$d(\alpha \mathbf{X}) = \alpha d\mathbf{X} \quad d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y}$$

➤ 乘积法则

$$\boxed{d(\mathbf{XY}) = (d\mathbf{X})\mathbf{Y} + \mathbf{X}(d\mathbf{Y})}$$

证明：令 $\mathbf{Z} = \mathbf{XY}$ ，则有

$$z_{ij} = \sum_{k=1}^n x_{ik} y_{kj}$$

根据标量微分的乘积法则有

$$d(z_{ij}) = d \sum_{k=1}^n x_{ik} y_{kj} = \sum_{k=1}^n d(x_{ik} y_{kj}) = \sum_{k=1}^n ((dx_{ik}) y_{kj} + x_{ik} (dy_{kj}))$$

从而 $d(\mathbf{XY}) = (d\mathbf{X})\mathbf{Y} + \mathbf{X}(d\mathbf{Y})$

矩阵微分

□ 常用矩阵微分公式

➤ 矩阵的逆的微分

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} (d\mathbf{X}) \mathbf{X}^{-1}$$

请尝试证明！

➤ 矩阵微分算子和迹算子的可交换性

$$d(\text{tr}(\mathbf{X})) = \text{tr}(d(\mathbf{X})) = \sum_{i=1}^n dx_{ii}$$

□ 任意 $n \times n$ 矩阵 \mathbf{A} 的迹的定义为其对角线的和，
即

$$tr(\mathbf{A}) = \sum_{i=1}^n a_{ii}$$

因此，

$$\frac{\partial(tr(\mathbf{A}))}{\partial a_{ij}} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

这意味着

$$\frac{\partial(tr(\mathbf{A}))}{\partial \mathbf{A}} = \mathbf{I}_{n \times n}$$

□ 例：求 $tr(\mathbf{AXB})$ 相对于矩阵 \mathbf{X} 的梯度。其中

$\mathbf{A}, \mathbf{X}, \mathbf{B}$ 分别是 $p \times m, m \times n, n \times p$ 矩阵

方法1:

$$\begin{aligned} d(tr(\mathbf{AXB})) &= tr\left(\mathbf{A}\left(\sum_{i=1}^m \sum_{j=1}^n \mathbf{e}_i \hat{\mathbf{e}}_j^T dx_{ij}\right)\mathbf{B}\right) = \sum_{i=1}^m \sum_{j=1}^n tr(\mathbf{A}\mathbf{e}_i \hat{\mathbf{e}}_j^T \mathbf{B}) dx_{ij} \\ &= \sum_{i=1}^m \sum_{j=1}^n \hat{\mathbf{e}}_j^T \mathbf{B} \mathbf{A} \mathbf{e}_i dx_{ij} = \sum_{i=1}^m \sum_{j=1}^n (\mathbf{BA})_{ji} dx_{ij} = \sum_{i=1}^m \sum_{j=1}^n (\mathbf{A}^T \mathbf{B}^T)_{ij} dx_{ij} \end{aligned}$$

因此, $\frac{\partial tr(\mathbf{AXB})}{\partial x_{ij}} = (\mathbf{A}^T \mathbf{B}^T)_{ij}$

即, $\frac{\partial tr(\mathbf{AXB})}{\partial \mathbf{X}} = \mathbf{A}^T \mathbf{B}^T$

$tr(\mathbf{AB}) = tr(\mathbf{BA})$

□ 例：求 $tr(\mathbf{AXB})$ 相对于矩阵 \mathbf{X} 的梯度。其中 $\mathbf{A}, \mathbf{X}, \mathbf{B}$ 分别是 $p \times m, m \times n, n \times p$ 矩阵
方法2：

$$d(tr(\mathbf{AXB})) = tr(\mathbf{A}(d\mathbf{X})\mathbf{B}) = tr(\mathbf{BA}(d\mathbf{X}))$$

因此，

$$\frac{\partial tr(\mathbf{AXB})}{\partial \mathbf{X}} = (\mathbf{BA})^T = \mathbf{A}^T \mathbf{B}^T$$

- 例：求 $tr(\mathbf{A}\mathbf{X}^{-1}\mathbf{B})$ 相对于矩阵 \mathbf{X} 的梯度。其中 $\mathbf{A}, \mathbf{X}, \mathbf{B}$ 分别是 $p \times n, n \times n, n \times p$ 矩阵

$$\begin{aligned} \text{方法1: } d(tr(\mathbf{A}\mathbf{X}^{-1}\mathbf{B})) &= tr(d(\mathbf{A}\mathbf{X}^{-1}\mathbf{B})) = tr(\mathbf{A}(d\mathbf{X}^{-1})\mathbf{B}) \\ &= tr\left(-\mathbf{A}\left(\sum_{i=1}^n \sum_{j=1}^n \mathbf{X}^{-1} \mathbf{e}_i \mathbf{e}_j^T \mathbf{X}^{-1} dx_{ij}\right)\mathbf{B}\right) = -\sum_{i=1}^n \sum_{j=1}^n tr(\mathbf{A}\mathbf{X}^{-1} \mathbf{e}_i \mathbf{e}_j^T \mathbf{X}^{-1} \mathbf{B}) dx_{ij} \\ &= -\sum_{i=1}^n \sum_{j=1}^n \mathbf{e}_j^T \mathbf{X}^{-1} \mathbf{B} \mathbf{A} \mathbf{X}^{-1} \mathbf{e}_i dx_{ij} = -\sum_{i=1}^n \sum_{j=1}^n (\mathbf{X}^{-1} \mathbf{B} \mathbf{A} \mathbf{X}^{-1})_{ji} dx_{ij} \\ &= -\sum_{i=1}^n \sum_{j=1}^n (\mathbf{X}^{-T} \mathbf{A}^T \mathbf{B}^T \mathbf{X}^{-T})_{ij} dx_{ij} \end{aligned}$$

因此，
$$\frac{\partial tr(\mathbf{A}\mathbf{X}^{-1}\mathbf{B})}{\partial x_{ij}} = -(\mathbf{X}^{-T} \mathbf{A}^T \mathbf{B}^T \mathbf{X}^{-T})_{ij}$$

即，
$$\frac{\partial tr(\mathbf{A}\mathbf{X}^{-1}\mathbf{B})}{\partial \mathbf{X}} = -\mathbf{X}^{-T} \mathbf{A}^T \mathbf{B}^T \mathbf{X}^{-T}$$

- 例：求 $tr(\mathbf{A}\mathbf{X}^{-1}\mathbf{B})$ 相对于矩阵 \mathbf{X} 的梯度。其中 $\mathbf{A}, \mathbf{X}, \mathbf{B}$ 分别是 $p \times n, n \times n, n \times p$ 矩阵
方法2：

$$\begin{aligned} d\left(tr\left(\mathbf{A}\mathbf{X}^{-1}\mathbf{B}\right)\right) &= tr\left(\mathbf{A}\left(d\mathbf{X}^{-1}\right)\mathbf{B}\right) \\ &= -tr\left(\mathbf{A}\mathbf{X}^{-1}\left(d\mathbf{X}\right)\mathbf{X}^{-1}\mathbf{B}\right) = -tr\left(\mathbf{X}^{-1}\mathbf{B}\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}\right) \end{aligned}$$

因此，
$$\frac{\partial tr\left(\mathbf{A}\mathbf{X}^{-1}\mathbf{B}\right)}{\partial \mathbf{X}} = -\left(\mathbf{X}^{-1}\mathbf{B}\mathbf{A}\mathbf{X}^{-1}\right)^T = -\mathbf{X}^{-T}\mathbf{A}^T\mathbf{B}^T\mathbf{X}^{-T}$$

□ 例：求 $tr(\mathbf{X}^T \mathbf{X})$ 相对于矩阵 \mathbf{X} 的梯度

方法1 $d(tr(\mathbf{X}^T \mathbf{X})) = tr(d(\mathbf{X}^T \mathbf{X})) = tr((d\mathbf{X}^T)\mathbf{X} + \mathbf{X}^T d\mathbf{X})$

$$\begin{aligned} &= tr\left(\left(\sum_{i=1}^m \sum_{j=1}^n \hat{\mathbf{e}}_j \mathbf{e}_i^T dx_{ij}\right) \mathbf{X} + \mathbf{X}^T \left(\sum_{i=1}^m \sum_{j=1}^n \mathbf{e}_i \hat{\mathbf{e}}_j^T dx_{ij}\right)\right) \\ &= \sum_{i=1}^m \sum_{j=1}^n tr(\hat{\mathbf{e}}_j \mathbf{e}_i^T \mathbf{X}) dx_{ij} + \sum_{i=1}^m \sum_{j=1}^n tr(\mathbf{X}^T \mathbf{e}_i \hat{\mathbf{e}}_j^T) dx_{ij} \\ &= \sum_{i=1}^m \sum_{j=1}^n \mathbf{e}_i^T \mathbf{X} \hat{\mathbf{e}}_j dx_{ij} + \sum_{i=1}^m \sum_{j=1}^n \hat{\mathbf{e}}_j^T \mathbf{X}^T \mathbf{e}_i dx_{ij} \\ &= 2 \sum_{i=1}^m \sum_{j=1}^n \mathbf{e}_i^T \mathbf{X} \hat{\mathbf{e}}_j dx_{ij} = 2 \sum_{i=1}^m \sum_{j=1}^n (\mathbf{X})_{ij} dx_{ij} \end{aligned}$$

因此, $\frac{\partial tr(\mathbf{X}^T \mathbf{X})}{\partial x_{ij}} = 2(\mathbf{X})_{ij}$ 即 $\frac{\partial tr(\mathbf{X}^T \mathbf{X})}{\partial \mathbf{X}} = \frac{\partial tr(\mathbf{X} \mathbf{X}^T)}{\partial \mathbf{X}} = 2\mathbf{X}$

□ 例：求 $tr(\mathbf{X}^T \mathbf{X})$ 相对于矩阵 \mathbf{X} 的梯度

方法2:

$$d\left(tr(\mathbf{X}^T \mathbf{X})\right) = tr\left(d\left(\mathbf{X}^T \mathbf{X}\right)\right) = tr\left(\left(d\mathbf{X}^T\right) \mathbf{X} + \mathbf{X}^T d\mathbf{X}\right) = tr\left(\left(d\mathbf{X}^T\right) \mathbf{X}\right) + tr\left(\mathbf{X}^T d\mathbf{X}\right)$$

而

$$tr\left(\left(d\mathbf{X}^T\right) \mathbf{X}\right) = tr\left(\left(d\mathbf{X}^T\right) \mathbf{X}\right)^T = tr\left(\mathbf{X}^T d\mathbf{X}\right)$$

因此， $d\left(tr(\mathbf{X}^T \mathbf{X})\right) = 2tr\left(\mathbf{X}^T d\mathbf{X}\right)$

所以， $\frac{\partial tr(\mathbf{X}^T \mathbf{X})}{\partial \mathbf{X}} = \frac{\partial tr(\mathbf{X} \mathbf{X}^T)}{\partial \mathbf{X}} = 2(\mathbf{X}^T)^T = 2\mathbf{X}$

常用公式

$$tr(\mathbf{X} \mathbf{X}^T) = \|\mathbf{X}\|_F^2$$

□ 例：求 $tr(\mathbf{X}^T \mathbf{X})$ 相对于矩阵 \mathbf{X} 的梯度
方法3：

$$tr(\mathbf{X}^T \mathbf{X}) = \|\mathbf{X}\|_F^2 = vec(\mathbf{X})^T vec(\mathbf{X})$$

$$\frac{\partial tr(\mathbf{X}^T \mathbf{X})}{\partial \mathbf{X}} = uvec \left(\frac{\partial (vec(\mathbf{X})^T vec(\mathbf{X}))}{\partial vec(\mathbf{X})} \right)$$

$$= 2uvec(vec(\mathbf{X})) = 2\mathbf{X}$$

□ 例：求 $f(\mathbf{A}) = \mathbf{x}^T \mathbf{A} \mathbf{y}$ 相对于矩阵 \mathbf{A} 的梯度。

方法3:

$$\begin{aligned} df(\mathbf{A}) &= d(\mathbf{x}^T \mathbf{A} \mathbf{y}) = d(\text{tr}(\mathbf{x}^T \mathbf{A} \mathbf{y})) \\ &= d(\text{tr}(\mathbf{y} \mathbf{x}^T \mathbf{A})) = \text{tr}(\mathbf{y} \mathbf{x}^T d\mathbf{A}) \end{aligned}$$

$$\frac{\partial f(\mathbf{A})}{\partial \mathbf{A}} = (\mathbf{y} \mathbf{x}^T)^T = \mathbf{x} \mathbf{y}^T$$

实值函数相对于实向量的梯度



□ 例4 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$

方法2:

$$\begin{aligned} d(f(\mathbf{x})) &= d(\text{tr}(\mathbf{x}^T \mathbf{A} \mathbf{x})) = \text{tr}(d(\mathbf{x}^T \mathbf{A} \mathbf{x})) \\ &= \text{tr}((d\mathbf{x}^T) \mathbf{A} \mathbf{x} + \mathbf{x}^T \mathbf{A} d\mathbf{x}) = \text{tr}(\mathbf{x}^T \mathbf{A}^T d\mathbf{x} + \mathbf{x}^T \mathbf{A} d\mathbf{x}) \\ &= \text{tr}((\mathbf{x}^T \mathbf{A}^T + \mathbf{x}^T \mathbf{A}) d\mathbf{x}) \end{aligned}$$

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \mathbf{A} \mathbf{x} + \mathbf{A}^T \mathbf{x}$$

□ 关于迹的梯度的常用公式

$$1. \frac{\partial \text{tr}(\mathbf{X})}{\partial \mathbf{X}} = \mathbf{I}_{n \times n}$$

$$2. \frac{\partial \text{tr}(\mathbf{X}^{-1})}{\partial \mathbf{X}} = -(\mathbf{X}^{-2})^T$$

$$3. \frac{\partial \text{tr}(\mathbf{X}\mathbf{A})}{\partial \mathbf{X}} = \frac{\partial \text{tr}(\mathbf{A}\mathbf{X})}{\partial \mathbf{X}} = \mathbf{A}^T$$

$$4. \frac{\partial \text{tr}(\mathbf{X}^T \mathbf{A})}{\partial \mathbf{X}} = \frac{\partial \text{tr}(\mathbf{A}\mathbf{X}^T)}{\partial \mathbf{X}} = \mathbf{A}$$

$$5. \frac{\partial \text{tr}(\mathbf{X}^2)}{\partial \mathbf{X}} = 2\mathbf{X}^T$$

$$6. \frac{\partial \text{tr}(\mathbf{A}\mathbf{X}^{-1})}{\partial \mathbf{X}} = -(\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1})^T$$

$$7. \frac{\partial \text{tr}(\mathbf{X}^T \mathbf{A} \mathbf{X})}{\partial \mathbf{X}} = (\mathbf{A} + \mathbf{A}^T) \mathbf{X}$$

$$8. \frac{\partial \text{tr}(\mathbf{X}\mathbf{A}\mathbf{X}^T)}{\partial \mathbf{X}} = \mathbf{X}(\mathbf{A} + \mathbf{A}^T)$$

$$9. \frac{\partial \text{tr}(\mathbf{A}\mathbf{X}\mathbf{X}^T \mathbf{A}^T)}{\partial \mathbf{X}} = 2\mathbf{A}^T \mathbf{A} \mathbf{X}$$

$$10. \frac{\partial \text{tr}(\mathbf{A}\mathbf{X}\mathbf{X}^T \mathbf{B})}{\partial \mathbf{X}} = (\mathbf{B}\mathbf{A} + \mathbf{A}^T \mathbf{B}^T) \mathbf{X}$$

- 同矩阵的迹一样，矩阵的行列式也是以矩阵为自变量的标量函数，因此同样存在行列式相对于矩阵梯度问题。由于行列式明显的几何意义（体积），它在很多学科都有着广泛的应用。行列式相对于矩阵的梯度问题也几乎贯穿所有行列式优化问题。

$$\text{行列式定义: } |\mathbf{X}| = \sum_{i=1}^n x_{ij} C_{ij} \text{ 或者 } |\mathbf{X}| = \sum_{j=1}^n x_{ij} C_{ij}$$

$$\text{代数余子式矩阵: } \mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \cdots & C_{1n} \\ C_{21} & C_{22} & \cdots & C_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ C_{n1} & C_{n2} & \cdots & C_{nn} \end{bmatrix}, \quad C_{ij} = (-1)^{i+j} M_{ij}$$

$$\text{伴随矩阵: } \mathbf{X}^* = \mathbf{C}^T$$

行列式的矩阵梯度



□ 对于一个方阵 \mathbf{X} , 有

$$\frac{\partial |\mathbf{X}|}{\partial x_{ij}} = C_{ij}$$

因此,
$$\boxed{\frac{\partial |\mathbf{X}|}{\partial \mathbf{X}} = \mathbf{C} = \left(\mathbf{X}^*\right)^T = |\mathbf{X}| \mathbf{X}^{-T}}$$

$$\mathbf{X}^{-1} = \frac{\mathbf{X}^*}{|\mathbf{X}|}$$

微分形式: $d|\mathbf{X}| = \text{tr}(|\mathbf{X}| \mathbf{X}^{-1} d\mathbf{X})$

□ 例. $|\mathbf{AXB}|$ 相对于矩阵 \mathbf{X} 的梯度

$$\begin{aligned}d|\mathbf{AXB}| &= \text{tr}\left(\left(|\mathbf{AXB}|(\mathbf{AXB})^{-1}\right)d(\mathbf{AXB})\right) \\&= \text{tr}\left(\left(|\mathbf{AXB}|(\mathbf{AXB})^{-1}\right)\mathbf{A}(d\mathbf{X})\mathbf{B}\right) \\&= \text{tr}\left(\left(|\mathbf{AXB}|\mathbf{B}(\mathbf{AXB})^{-1}\right)\mathbf{A}(d\mathbf{X})\right)\end{aligned}$$

因此,

$$\begin{aligned}\frac{\partial |\mathbf{AXB}|}{\partial \mathbf{X}} &= \left(\left(|\mathbf{AXB}|\mathbf{B}(\mathbf{AXB})^{-1}\right)\mathbf{A}\right)^{\text{T}} \\&= |\mathbf{AXB}|\mathbf{A}^{\text{T}}\left(\mathbf{B}^{\text{T}}\mathbf{X}^{\text{T}}\mathbf{A}^{\text{T}}\right)^{-1}\mathbf{B}^{\text{T}}\end{aligned}$$

常用的行列书关于矩阵求导的公式

$$1. \frac{\partial |\mathbf{X}|}{\partial \mathbf{X}} = |\mathbf{X}| \mathbf{X}^{-\text{T}}$$

$$2. \frac{\partial |\mathbf{X}^{-1}|}{\partial \mathbf{X}} = -\frac{\mathbf{X}^{-\text{T}}}{|\mathbf{X}|}$$

$$3. \frac{\partial \log |\mathbf{X}|}{\partial \mathbf{X}} = \mathbf{X}^{-\text{T}}$$

$$4. \frac{\partial |\mathbf{X}\mathbf{X}^{\text{T}}|}{\partial \mathbf{X}} = 2|\mathbf{X}\mathbf{X}^{\text{T}}|(\mathbf{X}\mathbf{X}^{\text{T}})^{-1} \mathbf{X} \quad \text{rank}(\mathbf{X}_{m \times n}) = m$$

$$5. \frac{\partial |\mathbf{X}^{\text{T}}\mathbf{X}|}{\partial \mathbf{X}} = 2|\mathbf{X}^{\text{T}}\mathbf{X}|\mathbf{X}(\mathbf{X}^{\text{T}}\mathbf{X})^{-1} \quad \text{rank}(\mathbf{X}_{m \times n}) = n$$

常用的行列书关于矩阵求导的公式

$$6. \frac{\partial |\mathbf{X}^2|}{\partial \mathbf{X}} = 2|\mathbf{X}|^2 \mathbf{X}^{-\mathrm{T}} \quad \text{rank}(\mathbf{X}_{m \times m}) = m$$

$$7. \frac{\partial |\mathbf{AXB}|}{\partial \mathbf{X}} = |\mathbf{AXB}| \mathbf{A}^{\mathrm{T}} (\mathbf{B}^{\mathrm{T}} \mathbf{X}^{\mathrm{T}} \mathbf{A}^{\mathrm{T}})^{-1} \mathbf{B}^{\mathrm{T}}$$

$$8. \frac{\partial |\mathbf{X}^{\mathrm{T}} \mathbf{A} \mathbf{X}|}{\partial \mathbf{X}} = |\mathbf{X}^{\mathrm{T}} \mathbf{A} \mathbf{X}| \left(\mathbf{A} \mathbf{X} (\mathbf{X}^{\mathrm{T}} \mathbf{A} \mathbf{X})^{-1} + \mathbf{A}^{\mathrm{T}} \mathbf{X} (\mathbf{X}^{\mathrm{T}} \mathbf{A}^{\mathrm{T}} \mathbf{X})^{-1} \right) \quad \mathbf{A} \text{不是对称矩阵}$$

$$9. \frac{\partial |\mathbf{X}^{\mathrm{T}} \mathbf{A} \mathbf{X}|}{\partial \mathbf{X}} = 2|\mathbf{X}^{\mathrm{T}} \mathbf{A} \mathbf{X}| \mathbf{A} \mathbf{X} (\mathbf{X}^{\mathrm{T}} \mathbf{A} \mathbf{X})^{-1} \quad \mathbf{A} \text{是对称矩阵}$$

□ 实值函数 $f(\mathbf{x})$ 相对于实向量 \mathbf{x} 的二阶偏导数（称为Hessian矩阵），定义为：

$$\frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \frac{\partial}{\partial \mathbf{x}^T} \left(\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right)$$

或者写为梯度的梯度，

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}^T} (\nabla_{\mathbf{x}} f(\mathbf{x}))$$

$$\frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2 \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{bmatrix}$$

Hessian矩阵有许多重要应用，比如经典的**SURF**特征点检测算子就直接以其为核心：为了实现尺度不变性的特征点检测与匹配，**SURF**算法则先利用Hessian矩阵确定候选点，然后进行非极大抑制，大大降低了时间复杂度。

□ 实值函数 $f(\mathbf{x})$ 的泰勒级数展开

方向导数

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \boxed{(\nabla_{\mathbf{x}} f(\mathbf{x}))^T \Delta\mathbf{x}} + \frac{1}{2} \boxed{(\Delta\mathbf{x})^T \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \Delta\mathbf{x}} + \dots$$

$$\frac{\partial(\mathbf{g}^T(\mathbf{x})\mathbf{h}(\mathbf{x}))}{\partial\mathbf{x}} = \frac{\partial\mathbf{g}(\mathbf{x})^T}{\partial\mathbf{x}}\mathbf{h}(\mathbf{x}) + \frac{\partial\mathbf{h}(\mathbf{x})^T}{\partial\mathbf{x}}\mathbf{g}(\mathbf{x}) \qquad \frac{\partial\mathbf{g}^T}{\partial\mathbf{x}} = \left(\frac{\partial\mathbf{g}}{\partial\mathbf{x}^T} \right)^T$$

□ 讨论1：如何得到二阶方向导数的表达式？

□ 讨论2：更高阶方向导数的表达式？

□ 实值函数 $f(\mathbf{x})$ 的局部极值条件

如果 \mathbf{x}_* 是 $f(\mathbf{x})$ 的局部极小值, 并且 $\nabla_{\mathbf{x}}^2 f(\mathbf{x})$ 在 \mathbf{x}_* 的开邻域 $\Delta \mathbf{x}$ 内连续, 则

$$\nabla_{\mathbf{x}} f(\mathbf{x}_*) = \mathbf{0}, \quad \nabla_{\mathbf{x}}^2 f(\mathbf{x}_*) \geq \mathbf{0}$$


其中 $\nabla_{\mathbf{x}}^2 f(\mathbf{x}_*) \geq \mathbf{0}$ 代表 Hessian 矩阵 $\nabla_{\mathbf{x}}^2 f(\mathbf{x})$ 是半正定的。

□例：实值函数 $f(\mathbf{x})$ 的极值

$$f(x, y) = x^2 + y^2 + 1$$

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} 2x \\ 2y \end{bmatrix} \stackrel{\text{令}}{=} \mathbf{0} \Rightarrow x = 0, y = 0$$

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$




□例：实值函数 $f(\mathbf{x})$ 的极值

$$f(x, y) = x^3 + y^3 - 3x - 3y + 1$$

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} 3x^2 - 3 \\ 3y^2 - 3 \end{bmatrix} \stackrel{\text{令}}{=} \mathbf{0} \Rightarrow x = \pm 1, y = \pm 1$$

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} 6x & 0 \\ 0 & 6y \end{bmatrix}$$



一般的包含等式约束的优化模型形式如下：

$$\begin{cases} \min_{\mathbf{x} \in \mathbb{R}^{n \times 1}} & f(\mathbf{x}) \\ \text{s.t.} & g(\mathbf{x}) = 0. \end{cases}$$

约束优化模型的拉格朗日函数定义如下：

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) - \lambda g(\mathbf{x})$$

定理 1 (二阶必要性条件) 假设对任意向量 $\mathbf{w} \in C$,

$$\mathbf{w}^T \nabla^2 \mathcal{L}(\mathbf{x}^*, \lambda^*) \mathbf{w} \geq 0$$

成立, 则 \mathbf{x}^* 为优化问题的局部极值点。在此, 集合 C 被定义为

$$C = \{\mathbf{w} \in \mathbb{R}^n | (\nabla g)^T \mathbf{w} = 0\} = \text{Null}[(\nabla g)^T],$$

其中, $\text{Null}(\mathbf{A})$ 表示 \mathbf{A} 的零空间; $\nabla^2 \mathcal{L}(\mathbf{x}^*, \lambda^*)$ 为拉格朗日函数在 $(\mathbf{x}^*, \lambda^*)$ 处的二阶Hessian矩阵; ∇g 为约束函数的一阶梯度。

约束条件 $g(\mathbf{x})$ 的一阶泰勒展开:

$$g(\mathbf{x} + \mathbf{w}) \approx g(\mathbf{x}) + (\nabla g)^T \mathbf{w}$$

由于 \mathbf{w} 始终位于 $(\nabla g)^T$ 的零空间中, 假设该零空间的维度为 m ($m < n$), 矩阵 $\mathbf{Z} \in \mathbb{R}^{n \times m}$ 的列向量构成零空间的一组基, 则 \mathbf{w} 可以表示为

$$\mathbf{w} = \mathbf{Z}\mathbf{v}$$

其中, $\mathbf{v} \in \mathbb{R}^{m \times 1}$ 为相应的组合系数。

$$\mathbf{w} = \mathbf{Z}\mathbf{v}$$

$$\mathbf{w}^T \nabla^2 \mathcal{L}(\mathbf{x}^*, \lambda^*) \mathbf{w} \geq 0$$



$$\mathbf{v}^T \mathbf{Z}^T \nabla^2 \mathcal{L}(\mathbf{x}^*, \lambda^*) \mathbf{Z} \mathbf{v} \geq 0$$



$$\mathbf{Z}^T \nabla^2 \mathcal{L}(\mathbf{x}^*, \lambda^*) \mathbf{Z} \geq 0$$

投影Hessian矩阵

对于有约束优化模型，二阶必要性条件等价于判断投影Hessian矩阵的正定性

获取矩阵 \mathbf{Z} 的一种方法是对 ∇g 执行QR 分解，其中有

$$\nabla g = \mathbf{Q} \begin{bmatrix} \mathbf{R} \\ \mathbf{0} \end{bmatrix} = \begin{bmatrix} \mathbf{Q}_1 & \mathbf{Q}_2 \end{bmatrix} \begin{bmatrix} \mathbf{R} \\ \mathbf{0} \end{bmatrix} = \mathbf{Q}_1 \mathbf{R},$$

其中， \mathbf{Q} 为 $n \times n$ 正交矩阵，进而可以令 $\mathbf{Z} = \mathbf{Q}_2$ ，因为

$$(\nabla g)^T \mathbf{w} = \mathbf{R}^T \mathbf{Q}_1^T \mathbf{Q}_2 \mathbf{v} = 0.$$

Reference:

J. Nocedal and S. J. Wright, Numerical Optimization. New York, NY, USA: Springer, 1999.

无约束优化与约束优化模型二阶局部极值条件的对比

| 模型 | 二阶必要性条件 | 对比 |
|--|--|--------------|
| $\min_{\mathbf{x}} f(\mathbf{x})$ | $\nabla^2 f(\mathbf{x}^*) \geq 0$ | Hessian 矩阵 |
| $\begin{cases} \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{s.t. } g(\mathbf{x}) = 0. \end{cases}$ | $\mathbf{Z}^T \nabla^2 \mathcal{L}(\mathbf{x}^*, \lambda^*) \mathbf{Z} \geq 0$ | 投影Hessian 矩阵 |

□与Hessian矩阵相关的常用公式

$$1. \frac{\partial^2 \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x} \partial \mathbf{x}^T} = \mathbf{O}_{n \times n}$$

$$2. \frac{\partial^2 \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x} \partial \mathbf{x}^T} = \mathbf{A} + \mathbf{A}^T$$

$$3. \frac{\partial^2 \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x} \partial \mathbf{x}^T} = 2\mathbf{A} \quad \mathbf{A} \text{ 为对称矩阵时}$$



谢 谢

耿修瑞

中国科学院空间信息创新研究院

gengxr@sina.com.cn