



局部线性嵌入


耿修瑞

中科院空天信息创新研究院

gengxr@sina.com.cn

2025.4

- 问题背景
- 基本概念
- 局部线性嵌入



在上图中，右面的两个曲面都可以由左边的平面通过弯曲或者卷曲的方式得到。也就是说，从内蕴几何的角度，上述三个曲面本质上是同一个几何对象，他们在对应点处都有着相同的高斯曲率。三者相比，对平面上散点的研究显然更为便捷，因为平面为二维欧氏空间，线性代数为其上对象的研究提供了各种便利的工具。而对于右面的两个图，尽管我们可以把他们当做三维欧氏空间中的散点，利用三维线性空间中的各种工具对其进行处理，但处理的结果往往容易受到数据“弯曲”方式的影响，继而并不能真正体现数据本身的内蕴性质。为此，我们需要引入一种“化曲为直”的工具，将弯曲的数据展平，从而降低最终处理结果对数据“弯曲”方式的依赖。

定义1（拓扑空间）：拓扑空间是由一个集合和其上定义的拓扑构成的二元组 (X, \mathcal{D})

最常见的拓扑由一系列开集构成，当给定一个集合后，我们可以定义一个子集族 \mathcal{D} ，该子集族由集合 X 的子集构成，且满足如下条件：

- (1) $X, \emptyset \in \mathcal{D}$
- (2) $A, B \in \mathcal{D} \Rightarrow A \cap B \in \mathcal{D}$
- (3) $\{A_i\} \in \mathcal{D} \Rightarrow \cup A_i \in \mathcal{D}$

则称 \mathcal{D} 为 X 的**拓扑**，而 \mathcal{D} 中的元素称为 X 的**开集**。通俗地说，拓扑是一个子集族，该自己族满足：

- (1) 空集和全集都是开集
- (2) 有限个开集的交集是开集
- (3) 任意个开集的并集是开集

需要注意的是，拓扑是由人为指定的，任意满足如上定义的子集族都可以称为一个集合的拓扑。比如，对于一个只有两个元素的集合 $X = \{0,1\}$ ，我们既可以指定其上的拓扑为

$$\mathcal{D} = \{\emptyset, \{0\}, \{1\}, \{0,1\}\}$$

也可以指定其拓扑为

$$\mathcal{D} = \{\emptyset, \{0,1\}\}$$

可以看到，前者包含了集合的所有子集，该拓扑称作**离散拓扑**，而后者只包含空间和全集，是最简单的一个拓扑，因此称作**平凡拓扑**。

\mathbb{R}^n 上的开球:


$$B_r(\mathbf{x}) = \{\mathbf{y} \in \mathbb{R}^n \mid \|\mathbf{y} - \mathbf{x}\| < r\}$$

\mathbb{R}^n 上的拓扑:

$$\mathcal{D}_{std} = \{V \subset \mathbb{R}^n \mid \forall \mathbf{x} \in V, \exists r > 0, \text{使得 } B_r(\mathbf{x}) \subset V\}$$

此拓扑称为 \mathbb{R}^n 的标准拓扑。

在标准拓扑中, 对于任意一子集, 当且仅当集中任意一个点总能找到以该点为中心的一个开球, 并且该开球完全包含在子集中时, 它才是一个开集。而平面上包含边界的圆盘显然就不是一个开集。




在标准拓扑的基础上，我们可以利用诱导拓扑的概念给出线性上任意子集的拓扑，设 X 是 \mathbb{R}^n 中的任意非空子集，那么其上的诱导拓扑可以定义为：

$$\mathcal{D}_X = \{V \mid \exists O \in \mathcal{D}_{std}, \text{使得 } V = X \cap O\}$$

也就是说，对于 X 中的一个开集 V ，它必然是 \mathbb{R}^n 中某个开集与 X 的交集。下面给出了诱导拓扑意义下，平面上圆环的开集示意图。


线段、圆、球、长方形、四面体、立方体等这些几何体都可以看作是线性空间中的一个子集，因此基于诱导拓扑的概念，它们都可以看作是拓扑空间。




定义2（连续） 设 X, Y 是两个拓扑空间, $f: X \rightarrow Y$ 是一个映射。如果对于 Y 中任意开集 V , 其原像 $f^{-1}(V)$ 是 X 中的开集, 那么称 f 是一个连续映射。

定义3（同胚） 设 X, Y 是两个拓扑空间, 如果存在一个从 X 到 Y 的双射 $f: X \rightarrow Y$, 且 f 和 f^{-1} 都是连续映射, 那么称 X 和 Y 是同胚的。

连续（微积分中的定义）： 是指一个函数 $f(x)$ 在其定义域内的每一点 x_0 都连续。也就是说, 对于任何给定的 $\xi > 0$, 都存在一个 $\delta > 0$, 使得当 x 满足 $|x - x_0| < \delta$ 时, 有 $|f(x) - f(x_0)| < \xi$ 。



定义4（拓扑嵌入） 给定两个拓扑空间 X, Y ，以及一个从 X 到 Y 的连续单射 $f: X \rightarrow Y$ 。如果 X 与 $f(X)$ 同胚，则称 f 是一个拓扑嵌入。

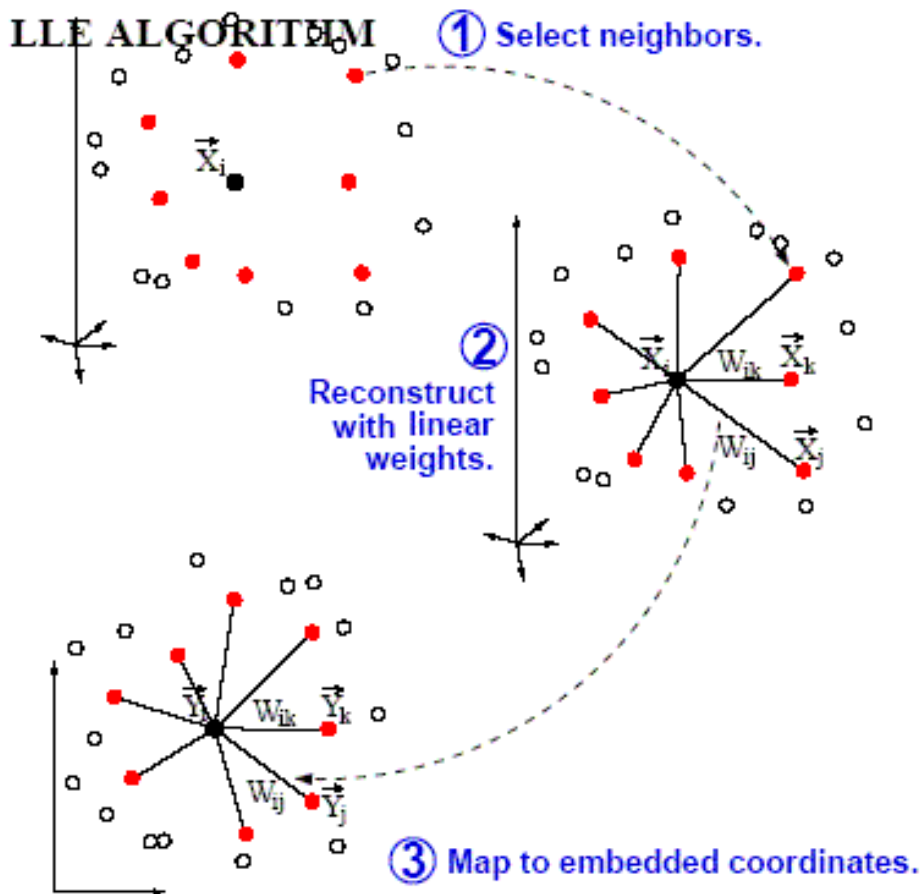


定义5（豪斯多夫空间） 设 X 是一个拓扑空间，如果其中的任意两点 x, y 都存在两个不相交的邻域，那么称 X 是一个豪斯多夫空间。

定义6（流形） 设 M 是一个豪斯多夫空间，若对其中任意一点 x ，都有一个 x 在 M 中的邻域 U 与 \mathbb{R}^n 中的一个开集同胚，那么称 M 是一个 n 维流形。

基本过程

1. Compute the neighbors of each data point, \vec{X}_i .
2. Compute the weights W_{ij} that best reconstruct each data point \vec{X}_i from its neighbors, minimizing the cost in Equation (1) by constrained linear fits.
3. Compute the vectors \vec{Y}_i best reconstructed by the weights W_{ij} , minimizing the quadratic form in Equation (2) by its bottom nonzero eigenvectors.



Roweis, S. T., & Saul, L. K. (2000). Nonlinear dimensionality reduction by locally linear embedding. Science, 290(5500), 2323-6.

基本过程2：对每一个点，计算邻域像元加权系数

$$\begin{cases} \min_{\mathbf{w}_i} RSS_i(\mathbf{w}_i) = \left\| \mathbf{x}_i - \sum_{j=1}^k w_{ij} \mathbf{x}_{ij} \right\|^2 \\ s.t. \sum_{j=1}^k w_{ij} = 1 \end{cases} \quad \text{为什么用和1约束?}$$

$$\mathbf{w}_i = (w_{i1}, w_{i2}, \dots, w_{ik})^T$$

$$\mathbf{Z}_i = (\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_k)^T = (\mathbf{x}_i - \mathbf{x}_{i1}, \mathbf{x}_i - \mathbf{x}_{i2}, \dots, \mathbf{x}_i - \mathbf{x}_{ik})^T$$

$$RSS_i(\mathbf{w}_i) = \mathbf{w}_i^T \mathbf{Z}_i \mathbf{Z}_i^T \mathbf{w}_i$$

$$L(\mathbf{w}_i, \lambda) = \frac{1}{2} \mathbf{w}_i^T \mathbf{Z}_i \mathbf{Z}_i^T \mathbf{w}_i - \lambda (\mathbf{1}^T \mathbf{w}_i - 1)$$

$$\mathbf{w}_i = \frac{(\mathbf{Z}_i \mathbf{Z}_i^T)^{-1} \mathbf{1}}{\mathbf{1}^T (\mathbf{Z}_i \mathbf{Z}_i^T)^{-1} \mathbf{1}}$$

基本过程3：降维，重构

$$\begin{cases} \min_{\mathbf{y}} \Phi(\mathbf{y}) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^k w_{ij} y_{ij} \right)^2 \\ s.t. \mathbf{y}^T \mathbf{y} = 1 \end{cases}$$

$$\begin{aligned} \Phi(\mathbf{y}) &= \sum_{i=1}^n \left(y_i - \sum_{j=1}^k w_{ij} y_{ij} \right)^2 = \sum_{i=1}^n \left(y_i^2 - y_i \sum_{j=1}^k w_{ij} y_{ij} - \left(\sum_{j=1}^k w_{ij} y_{ij} \right) y_i + \left(\sum_{j=1}^k w_{ij} y_{ij} \right)^2 \right) \\ &= \mathbf{y}^T \mathbf{y} - \mathbf{y}^T (\mathbf{W} \mathbf{y}) - (\mathbf{W} \mathbf{y})^T \mathbf{y} + (\mathbf{W} \mathbf{y})^T (\mathbf{W} \mathbf{y}) = ((\mathbf{I} - \mathbf{W}) \mathbf{y})^T ((\mathbf{I} - \mathbf{W}) \mathbf{y}) \\ &= \mathbf{y}^T (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W}) \mathbf{y} = \|\mathbf{y} - \mathbf{W} \mathbf{y}\|^2 \end{aligned}$$

$\mathbf{W} = (w_{ij})$ ，其中当 \mathbf{x}_j 是 \mathbf{x}_i 的邻域点的时候 w_{ij} 如上，否则 $w_{ij}=0$

$$\mathbf{M} = (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W})$$

$$\mathbf{M} \mathbf{y} = \lambda \mathbf{y}$$

\mathbf{M} 的最小特征值为0，所以要剔除第一个特征向量

例1.利用局部线性嵌入计算如下数据嵌入到R中的结果 ($k=4$)

$$\mathbf{X} = \begin{bmatrix} -1 & -0.924 & -0.707 & -0.383 & 0 & 0.383 & 0.707 & 0.924 & 1 \\ 0 & 0.383 & 0.707 & 0.924 & 1 & 0.924 & 0.707 & 0.383 & 0 \end{bmatrix}$$

对于第一个数据点，我们可以找到其最近的 4 个数据点，即第 2、3、4、5 个数据点

$$\mathbf{X}_1 = \begin{bmatrix} -0.924 & -0.707 & -0.383 & 0 \\ 0.383 & 0.707 & 0.924 & 1 \end{bmatrix}$$


相应地，

$$\mathbf{Z}_1 = \begin{bmatrix} -0.076 & -0.293 & -0.617 & -1 \\ -0.383 & -0.707 & -0.924 & -1 \end{bmatrix}^T$$

可以得到

$$\mathbf{w}_1 = [0.633 \quad 0.732 \quad 0.282 \quad -0.647]^T$$

因此， \mathbf{W} 的第一行元素为



因此， \mathbf{W} 的第一行元素为


$$\begin{bmatrix} 0 & 0.633 & 0.732 & 0.282 & -0.647 & 0 & 0 & 0 & 0 \end{bmatrix}$$

对所有的数据点都进行上述运算，可以得到权重矩阵为

$$\mathbf{W} = \begin{bmatrix} 0 & 0.633 & 0.732 & 0.282 & -0.647 & 0 & 0 & 0 & 0 \\ 0.918 & 0 & -0.379 & -0.161 & 0.621 & 0 & 0 & 0 & 0 \\ 0.397 & 0.103 & 0 & 0.103 & 0.397 & 0 & 0 & 0 & 0 \\ 0 & 0.397 & 0.103 & 0 & 0.103 & 0.397 & 0 & 0 & 0 \\ 0 & 0 & 0.397 & 0.103 & 0 & 0.103 & 0.397 & 0 & 0 \\ 0 & 0 & 0 & 0.397 & 0.103 & 0 & 0.103 & 0.397 & 0 \\ 0 & 0 & 0 & 0 & 0.397 & 0.103 & 0 & 0.103 & 0.397 \\ 0 & 0 & 0 & 0 & 0.621 & -0.161 & -0.379 & 0 & 0.918 \\ 0 & 0 & 0 & 0 & -0.647 & 0.282 & 0.732 & 0.633 & 0 \end{bmatrix}$$

令 $\mathbf{M} = (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W})$ ，计算其第二小特征值对应的特征向量，可得到嵌入结果为

$$\mathbf{y} = \begin{bmatrix} -0.515 & -0.377 & -0.275 & -0.132 & 0 & 0.132 & 0.275 & 0.377 & 0.515 \end{bmatrix}^T$$



在基本过程2中, $\mathbf{z}_i \mathbf{z}_i^T$ 一般都是奇异的, 此时, 局部表出系数的求解该如何处理?

$$\mathbf{w}_i = \frac{(\mathbf{z}_i \mathbf{z}_i^T)^{-1} \mathbf{1}}{\mathbf{1}^T (\mathbf{z}_i \mathbf{z}_i^T)^{-1} \mathbf{1}}$$

1. 岭回归思路 (讨论?)
2. 伪逆代替逆 (讨论?)

岭回归方法在解方程组时的的问题：

$$\begin{cases} 2x_1 + x_2 + x_3 = 3 \\ x_1 + 2x_2 + x_3 = 3 \end{cases}$$

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$$

$$\mathbf{x} = (\mathbf{A}^T \mathbf{A} + 0.1 \mathbf{I})^{-1} \mathbf{A}^T \mathbf{b}$$

$$\mathbf{Ax} = \mathbf{A} (\mathbf{A}^T \mathbf{A} + 0.1 \mathbf{I})^{-1} \mathbf{A}^T \mathbf{b} = \begin{bmatrix} 3.0073 \\ 2.9427 \end{bmatrix} \neq \begin{bmatrix} 3 \\ 3 \end{bmatrix}$$

伪逆法在解方程组时的的问题：

$$\begin{cases} 5x_1 + 7x_2 = 0.5 \\ 7x_1 + 10x_2 = 0.7 \end{cases}, \begin{cases} 5x_1 + 7x_2 = 0.51 \\ 7x_1 + 10x_2 = 0.69 \end{cases}$$

这两个方程组的精确解分别为：

$$\begin{bmatrix} 0.1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0.27 \\ -0.12 \end{bmatrix}$$

可见常数向量的微小差别便引起解的很大变动，其原因在于该方程组的系数矩阵的条件数非常大，即其最大奇异值和最小奇异值相差悬殊，此时对应的方程为病态方程。

此外，无论是岭回归方法，还是伪逆法，均只能给出方程或模型的一个解。事实上，当 $\mathbf{z}_i \mathbf{z}_i^T$ 不可逆时，方程或模型应该存在无穷多组解。于是，便有如下改进的局部线性嵌入方法。

改进的局部线性嵌入：
首先将过程2的优化模型改写为

$$\begin{cases} \min_{\mathbf{w}_i} \left\| \mathbf{x}_i - \sum_{j=1}^k w_{ij} \mathbf{x}_{ij} \right\|^2 = \|\mathbf{Z}_i^T \mathbf{w}_i\|^2 = \mathbf{w}_i^T \mathbf{R}_i \mathbf{w}_i \\ s.t. \mathbf{1}^T \mathbf{w}_i = 1 \end{cases}$$

其中 $\mathbf{R}_i = \mathbf{Z}_i \mathbf{Z}_i^T$ ，我们发现当 \mathbf{w}_i 取作 \mathbf{R}_i 的核空间的任意向量时，总可以使得优化模型的目标函数为0.假设其核空间的维数为 s ，我们可以取其中的一组基，

$\mathbf{v}_i^{(1)}, \mathbf{v}_i^{(2)}, \dots, \mathbf{v}_i^{(s)}$ ，则对于每一个 \mathbf{x}_i ，都可以构建 s 个局部表出系数向量 $\mathbf{w}_i^{(1)}, \mathbf{w}_i^{(2)}, \dots, \mathbf{w}_i^{(s)}$

其中

$$\mathbf{w}_i^{(k)} = \frac{\mathbf{v}_i^{(k)}}{\mathbf{1}^T \mathbf{v}_i^{(k)}}, \quad k = 1, 2, \dots, s$$

改进的局部线性嵌入：

对于每一组表出系数 $\{\mathbf{w}_i^{(k)}, i = 1, 2, \dots, n\}$ ，都可以按照局部线性嵌入的构建方式构建一个权重矩阵 \mathbf{W}_k ，相应地，根据局部线性嵌入的过程3，可有如下模型

$$\begin{cases} \min_{\mathbf{y}} \|\mathbf{y} - \mathbf{W}_k \mathbf{y}\|^2 = \mathbf{y}^T \mathbf{M}_k \mathbf{y} \\ s.t. \mathbf{y}^T \mathbf{y} = 1 \end{cases}$$

其中 $\mathbf{M}_k = (\mathbf{I} - \mathbf{W}_k)^T (\mathbf{I} - \mathbf{W}_k)$ ，则对于所有 s 组表出系数有

$$\sum_{i=1}^s \mathbf{y}^T \mathbf{M}_k \mathbf{y} = \mathbf{y}^T \left(\sum_{i=1}^s \mathbf{M}_k \right) \mathbf{y} = \mathbf{y}^T \mathbf{M} \mathbf{y},$$

然后利用 \mathbf{M} 对数据进行局部线性嵌入

讨论:

1. 多维尺度变换 (MDS): 保持点之间的欧氏距离
2. 等距特征映射 (Isomap): 保持点之间的测地距离
3. 拉普拉斯映射: 保留数据的局部邻接结构
4. 随机邻域嵌入 (t-SNE): 保持邻域的概率分布
5. 黑森局部线性嵌入 (HLLE): 保持局部二阶结构
6. 曲面的法曲率与高斯曲率
7. 高斯绝妙定理与曲面的可展性



谢 谢

耿修瑞

中科院空天信息创新研究院

gengxr@sina.com.cn